Python Analítico Nativo

Construyendo pipelines ETL sin dependencias externas

Un manual de arquitectura para extracción, limpieza y procesamiento estadístico utilizando únicamente la librería estándar de Python.

```
user@sys:~$ python main_pipeline.py --mode=vanilla
```

Gemini Notebook

La Filosofía Vanilla Python

Frameworks (ej. Pandas)



- Alta abstracción y dependencias pesadas
- Naturaleza de caja negra
- Requiere instalación de paquetes externos

Python Nativo



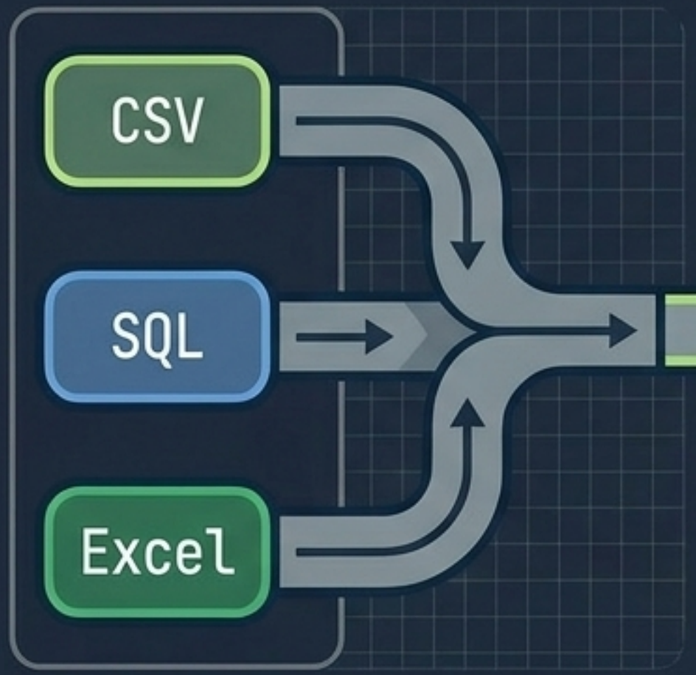
- Control absoluto sobre el flujo de ejecución
- Uso de librerías estándar (`csv`, `statistics`)
- Ejecución rápida y ubicua en cualquier entorno
- Exige comprensión profunda de la estructura de datos

El objetivo no es reemplazar a Pandas, sino comprender la arquitectura subyacente del procesamiento de datos.

Gemini Notebook

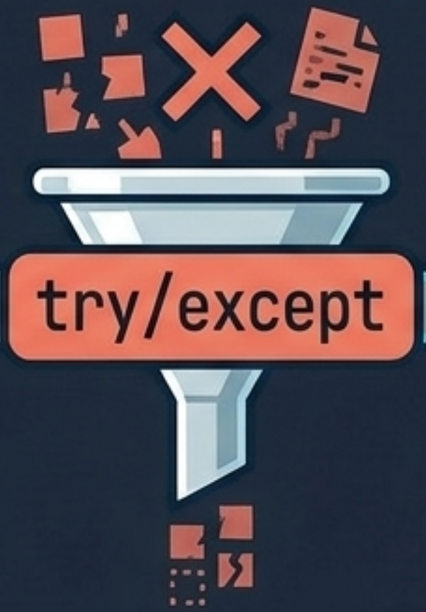
Arquitectura Modular del Script Universal

1. Extracción
(El Conector Variable)



El origen cambia, la estructura tabular resultante no.

2. Limpieza
(El Filtro de Seguridad)



Validación de longitud y conversión de tipos.

3. Motor Estadístico
(La Constante)



La lógica matemática es agnóstica al origen de los datos.

Gemini Notebook

Perfil de Datos: Salary_Data

6,704 Registros (Filas)

6 Variables (Columnas)

⚠ Estado: Contiene valores nulos (Requiere limpieza)

Estructura del Dataset					
Age					[INTEGER]
Gender					[STRING: Male, Female, Other]
Education Level					[STRING]
Job Title					[STRING: 193 categorías]
Years of Experience					[FLOAT]
Salary					[FLOAT: Variable objetivo]

Nota: Dataset enfocado en perfiles profesionales tecnológicos (ej. Data Scientist, Software Engineer).

Gemini Notebook

Matriz de Conectores: El Ecosistema de Extracción

Origen	Módulo Nativo	Método de Lectura	Gestión de Cabeceras	Formato de Salida
Archivo Plano (CSV)	import csv	Lector de texto fila a fila	next(lector)	Lista de Strings
Base Relacional (PostgreSQL)	import psycopg2	cursor.fetchall() (Tuplas)	Manejado en BD	Tipos Nativos
Hoja de Cálculo (Excel)	import openpyxl	ws.iter_rows()	Omitido vía min_row=2	Tipos Mixtos (requiere data_only)

Gemini Notebook

Extracción A: Archivos Planos (CSV)

```
with open(archivo, mode='r', encoding='utf-8') as f:
    content = f.read().lstrip('\ufeff')
    lector = csv.reader(content.splitlines())
    header = next(lector)
```

Prevención de Errores

Evita fallos críticos si el archivo contiene tildes o caracteres especiales.

Limpieza de BOM

Elimina el Byte Order Mark invisible que Excel inserta en los CSVs, evitando que la primera columna sea ilegible.

Separación Lógica

Aísla la cabecera de los datos estructurados para su posterior indexación.

Gemini Notebook

Extracción B: Bases de Datos (PostgreSQL)



PostgreSQL

```
SELECT age, years, salary
FROM salary_data
WHERE age IS NOT NULL...
```

Delegación de Limpieza

Usar `WHERE ... IS NOT NULL` permite que el motor de la base de datos asuma el trabajo pesado, entregando a Python registros previamente validados.

```
cursor.execute(consulta)

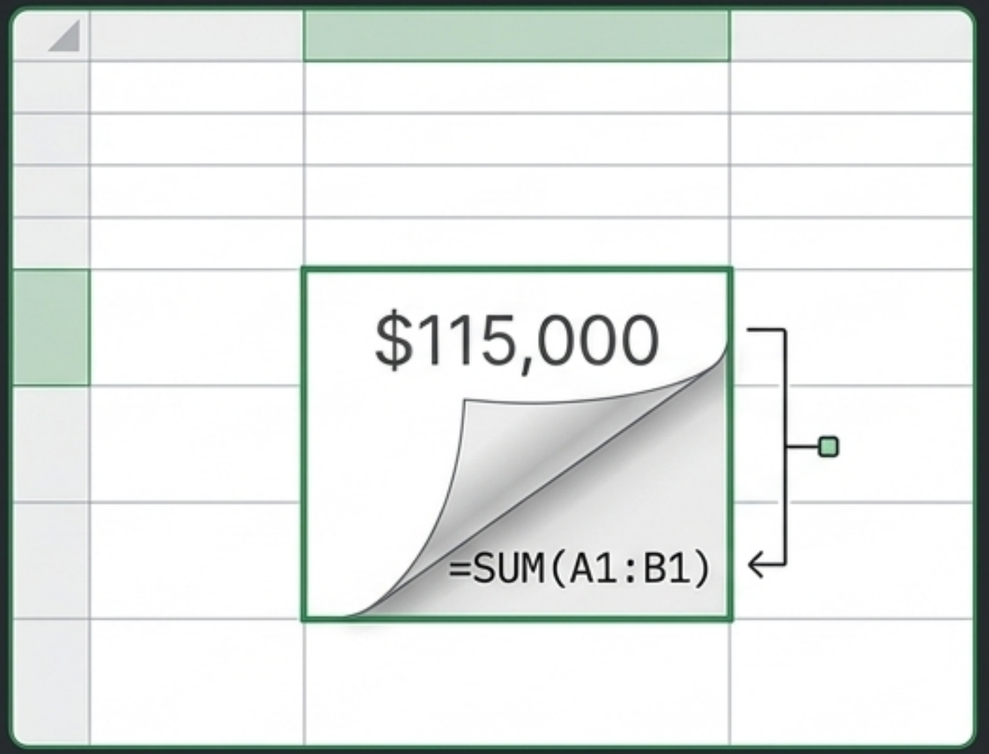
registros = cursor.fetchall()
```

El módulo psycopg2 devuelve una lista de tuplas con los tipos de datos numéricos ya pre-formateados, reduciendo la necesidad de castear strings.

Uso de **db_config para el paso seguro de credenciales (host, puerto, usuario).

Gemini Notebook

Extracción C: Hojas de Cálculo (Excel)



El **parámetro más crítico**. Garantiza Garantiza que Python lea los **valores numéricos** resultantes y no el código de texto de la fórmula subyacente.

```
wb = openpyxl.load_workbook(archivo_excel, data_only=True)
ws = wb.active
for row in ws.iter_rows(min_row=2, values_only=True):
```

Omite la fila de cabeceras directamente desde el iterador.

Extrae los datos limpios en lugar de los objetos de celda completos.

Gemini Notebook

El Motor Estadístico Centralizado

Listas limpias de números

```
ages
experiences
salaries
```

Black Box

```
def calcular_metricas(datos):
```

- Utiliza el módulo nativo `import statistics`.
- Calcula dinámicamente:
  `n (len)`,
  `Media (sum/n)`,
  `Mediana (statistics.median)`,
  `Mínimo, Máximo`.

⚠ Crucial Safeguard

```
statistics.stdev(datos) if n > 1 else 0
```

(Evita errores de división por cero si la lista es demasiado corta).

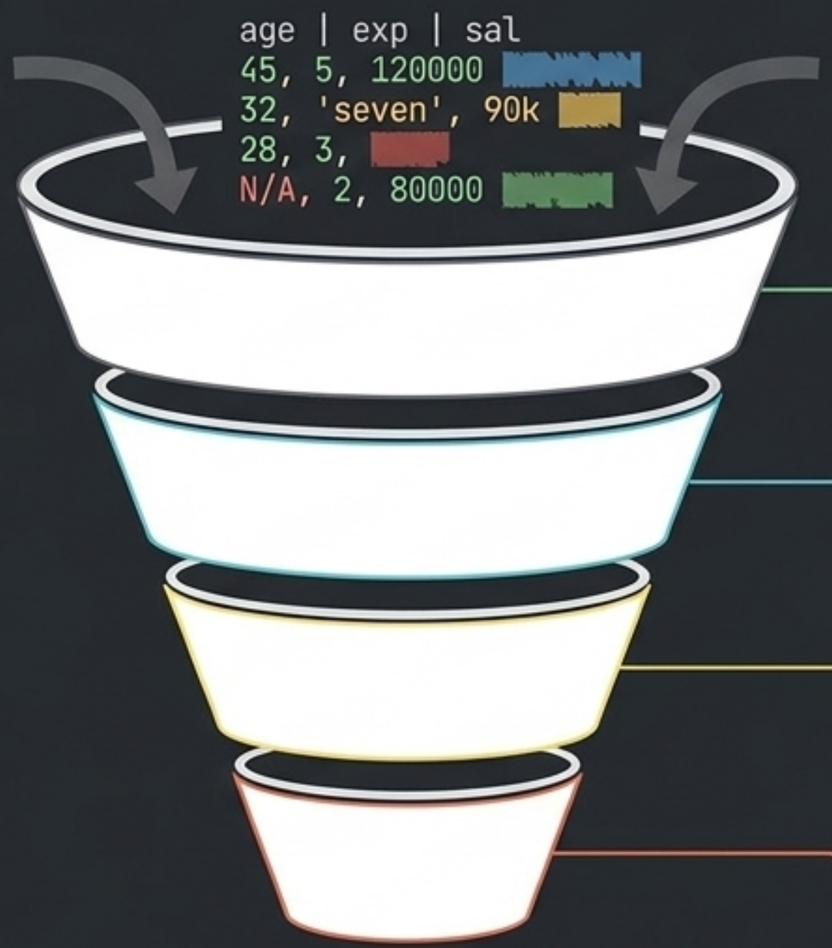
Resultado Centralizado

Un diccionario estructurado devolviendo todas las variables centralizadas y listas para formateo.

```
{
  "ages": age,
  "experiences": age,
  "mediana":salaries,
  "mínimo": [...],
  "salary": [...]
}
```

Gemini Notebook

La Barrera de Seguridad (Data Sanitization)




```
if len(fila) <= max(age_idx, exp_idx, sal_idx):
    continue
```

Validación de Longitud (IndexError). Descarta filas truncadas o incompletas.

```
.strip()
```

Extracción y Limpieza de Espacios. Elimina tabulaciones o espacios residuales en el texto.

```
try: float(valor)
```

Conversión de Tipo (TypeError / ValueError). Fuerza la tipificación matemática.

```
except ValueError: continue
```

La Válvula de Escape. Si encuentra celdas corruptas o texto anómalo, descarta la fila silenciosamente sin interrumpir la ejecución del programa.

Gemini Notebook

Resultados Formateados: Dashboard Salarial

KPI Card 1

Edad (*Age*)

Media: 33.62 | Mediana: 32.00

Rango: 21.00 - 62.00

Std Dev: 7.61

KPI Card 2

Años de Experiencia

Media: 8.09 | Mediana: 7.00

Rango: 0.00 - 34.00

Std Dev: 6.06

KPI Card 3

Salario

Media: $115,326.96 | Mediana: $115,000.00

Rango: $350.00 - $250,000.00

Std Dev: $52,786.18

Todo el formateo visual (moneda, separadores de miles, limitación a 2 decimales) se realiza de forma nativa vía f-strings: `f"${stats['media']:,.2f}"`

Gemini Notebook

Nuevo Escenario: Predicción de Churn Bancario

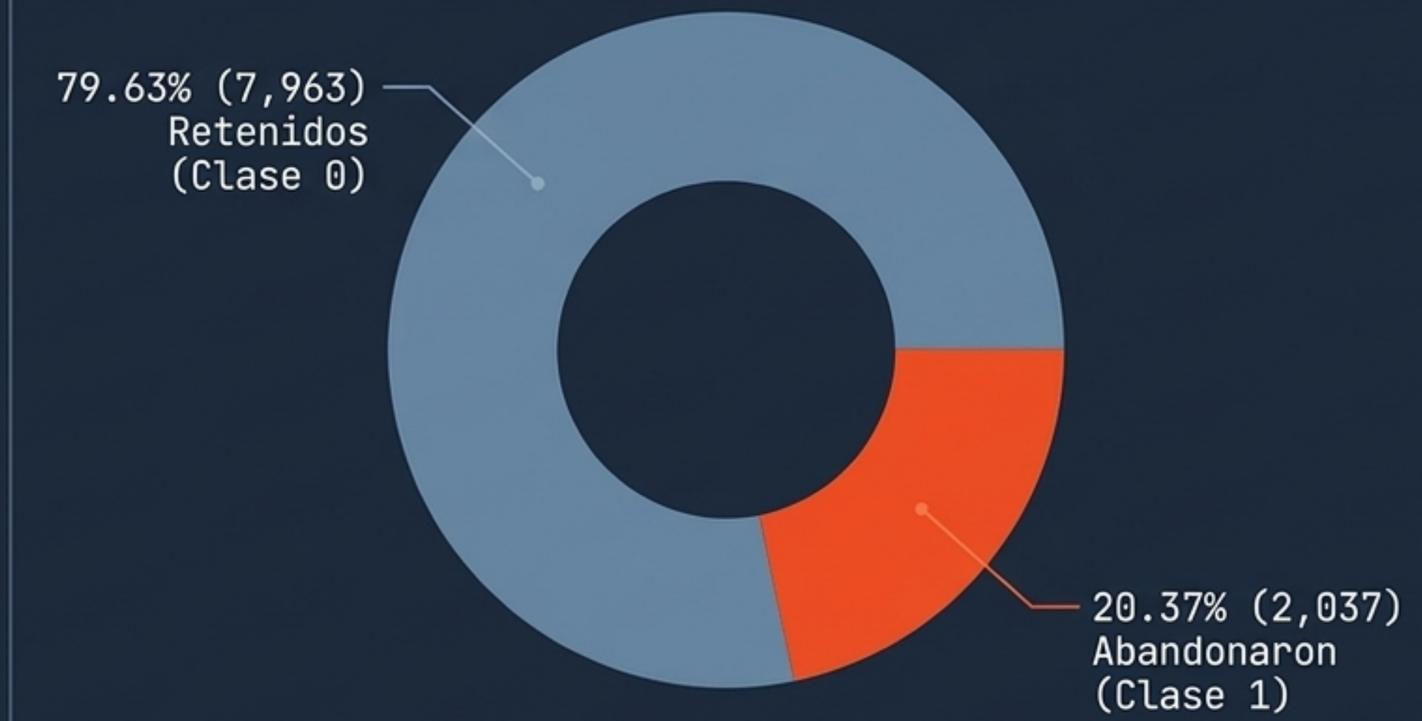
Dataset Profile Panel

10,000 Clientes | 12 Atributos

0 Valores Nulos

Variables Clave

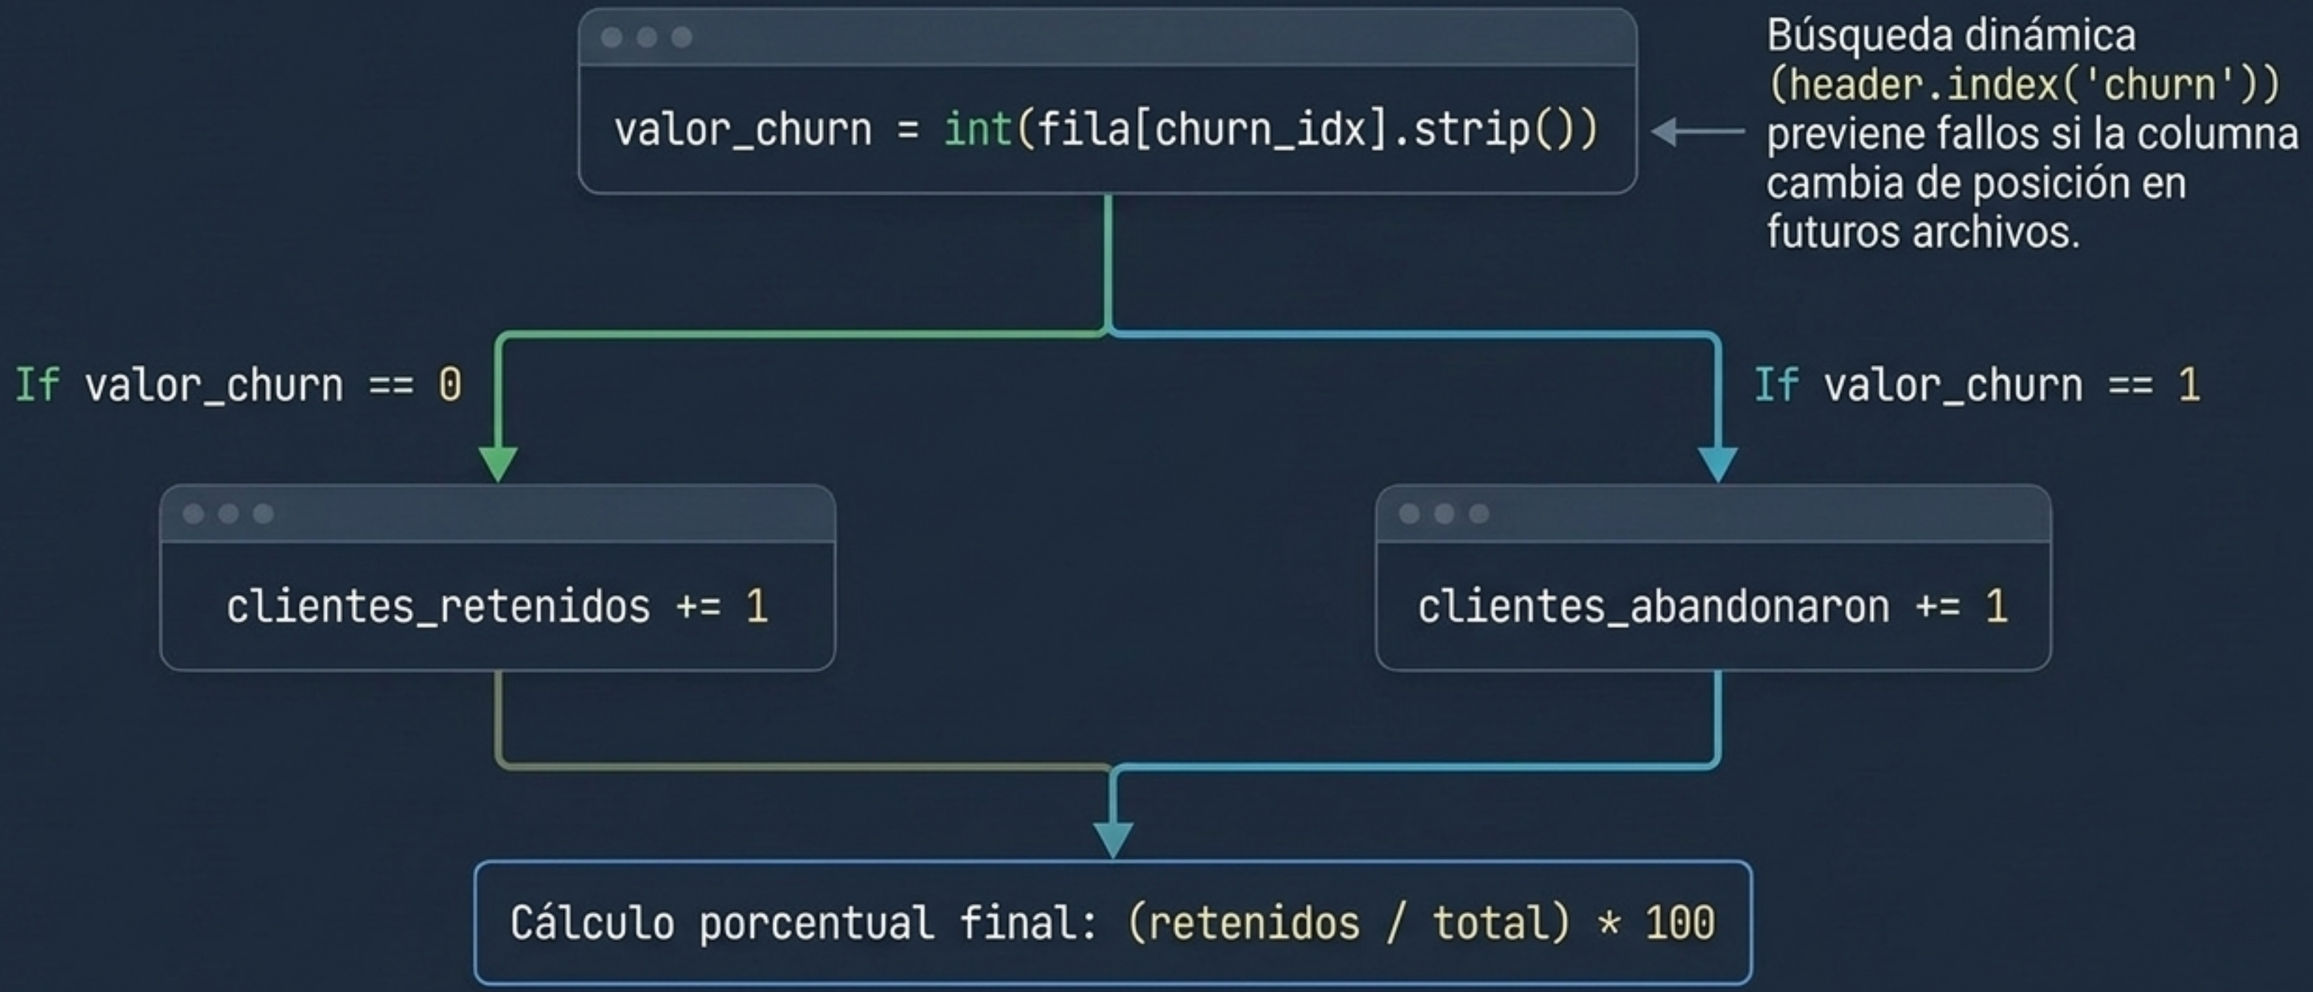
- credit_score
- balance (~$76k promedio)
- products_number
- active_member



Takeaway: Escenario clásico de desbalance de clases. Exige conteos absolutos precisos antes de entrenar cualquier modelo de Machine Learning predictivo.

Gemini Notebook

El Algoritmo de Conteo (Lógica Condicional)



Todo encapsulado dentro del bloque protector `try/except ValueError`.

Gemini Notebook

Síntesis: Patrones de Diseño en Python Puro



Mapeo Dinámico (Flexibilidad)

Nunca quemar en código (*hardcode*) las posiciones numéricas de las columnas. Usar siempre `header.index('Nombre')`. Hace al script resiliente a cambios estructurales.



Cierres Seguros (Gestión de Memoria)

Uso de bloques de contexto `with open(...)` para garantizar el cierre automático de conexiones de archivos, o bloques `try...finally` para clausurar cursores de bases de datos.



Fallo Silencioso Controlado (Resiliencia)

En pipelines de datos crudos, la anomalía es la norma. Usar `try-except` con `continue` previene caídas masivas por una sola celda corrupta.

Gemini Notebook

Maestría Analítica

"La maestría en la manipulación de datos no reside en conocer la librería externa más moderna, sino en dominar las estructuras de datos y el flujo lógico."

 - El conector de extracción cambia.

 - Las reglas de validación se adaptan.

Σ - La lógica matemática es universal.

```
>_ [Process completed. Output variables optimized. Exiting with code 0.]
```

Gemini Notebook